STEP 3 · 1~3주차

지하구조물 결함 탐지 프로젝트

균열·백태·박리를 한 번에 — YOLOv8s-Seg 인스턴스 세그멘테이션

개인 프로젝트

이미지 세그멘테이션

논문 기반 실습

이 강의가 다루는 연구

지하 콘크리트 구조물의 다중 표면 결함 탐지

Detection and Segmentation of Multiple Surface Defects in Underground Concrete Structures Using YOLOv8s-Seg

Yong Hwan Kim, Jung Hun Kim, Suk Min Kong, Seong Won Lee, Sang-Il Choi

대구가톨릭대학교 컴퓨터소프트웨어학부 · 한국건설기술연구원 지반연구본부

대상 결함	crack (균열) · efflorescence (백태) · spall_detach (박리·박락)
데이터	AI Hub 공개 데이터 기반 총 4,116장 · 세 결함을 polygon 기반 instance mask로 주석
모델	YOLOv8s-Seg (사전학습 가중치 미세조정)
핵심 성과	Test mask mAP50 = 0.443 · Image-level macro F1 = 0.896
특징	검증셋에서 클래스별 confidence threshold를 결정하고 테스트셋에 변경 없이 적용

마스크를 정확히 그리는 능력과 결함이 있는 영상을 골라내는 능력은 다르다. 이 차이를 이해하는 것이 이 강의의 핵심이다.

Step 3 프로젝트 한눈에 보기

3주 동안 무엇을 만들고 무엇을 제출하는가

진행 방법	개인 프로젝트 (1인 1실습 파이프라인 수행)
분야	이미지 인스턴스 세그멘테이션 · 지하 콘크리트 결함 분석
사용 알고리즘	YOLOv8s-Seg (Backbone + Neck + Detection/Segmentation Head)
입력	지하 콘크리트 구조물 표면 영상 · 입력 크기 960 (letterbox 적용)
출력	결함 3종의 클래스 · confidence · bounding box · instance mask
최종 산출물	학습·평가 코드 + 클래스별 임계값 탐색 결과 + FP·FN 오류 분석 리포트

STEP 3 · 개요

학습 목표

3주 후 학생이 스스로 할 수 있어야 하는 것

01	**문제를 정의한다**	분류·검출·세그멘테이션의 차이를 설명하고, 결함 분석 목적에 맞는 접근 방식을 선택할 수 있다
02	**데이터를 만든다**	폴리곤 주석 기준을 문서화하고 원본 단위 분할로 데이터 누수를 막을 수 있다
03	**모델을 학습한다**	YOLOv8s-Seg의 기본 구조와 학습 설정을 이해하고, 입력 크기와 증강 설정의 선택 근거를 설명할 수 있다
04	**두 축으로 평가한다**	mask mAP와 이미지 단위 ON/OFF 평가를 구분하고 각각이 무엇을 재는지 설명할 수 있다
05	**임계값을 설계한다**	클래스별 confidence threshold를 검증셋에서 결정하고, 테스트셋에 변경 없이 적용하는 절차를 수행할 수 있다

STEP 3 · 개요

3주 학습 로드맵

주차별 강의 내용과 제출물

1주차

결함 이해와 데이터 준비

- 결함 3종 이해
- 육안 점검의 한계
- 분류·검출·세그멘테이션 비교
- 주석 기준 수립

과제: 주석 기준서 + 하드 네거티브 사례 정리

2주차

주석·데이터 구축과 모델 학습

- 일부 샘플 폴리곤 주석
- 데이터 무결성 점검
- 원본 단위 분할
- YOLOv8s-Seg 학습

과제: 실습용 데이터셋 구축 + best.pt 확보

3주차

평가와 임계값

- mask mAP 평가
- 이미지 단위 ON/OFF 평가
- 검증셋 기반 클래스별 임계값 탐색
- FP·FN 분석

과제: 임계값 실험 + 최종 리포트

STEP 3 · 개요

평가 방법

두 축으로 나누어 채점한다

세그멘테이션 성능	**30%**	mask mAP50 기준 순위
ON/OFF 성능	**30%**	이미지 단위 macro F1 기준 순위
오류 분석	**25%**	FP·FN 사례의 원인 규명 깊이
재현성	**15%**	주석 기준서·시드·분할 고정 여부

임계값을 테스트셋에서 조정한 흔적이 발견되면 ON/OFF 점수는 인정하지 않는다. 절차를 지키는 것이 성능보다 중요하다.

PART 1 · 1주차

문제 정의와 배경

지하 구조물에서 무엇을 찾아야 하는가

지하 콘크리트 구조물

도시 기반시설의 보이지 않는 뼈대

대상 구조물

- 터널 (tunnel)
- 공동구 (utility tunnel) — 전력·통신·상수도 수용
- 지하차도 (underpass)
- 지하보도 (underground passage)

열화를 유발하는 조건

- 지하수 유입과 높은 습도
- 온·습도 변화 및 반복적인 건습 환경
- 외부 하중 및 콘크리트 재료의 장기 열화
- 시공 품질 및 초기 결함의 영향

왜 이 구조물들이 중요한가

- 교통·전력·통신·상수도 등 도시 기반시설의 안정적인 운영을 담당한다.
- 장기간 사용하면서 콘크리트 표면과 내부에 다양한 열화 및 손상이 발생할 수 있다.
- 균열, 누수, 백태, 박리·박락, 철근 노출, 단면 손실 등이 대표적인 이상 상태이며 지속적인 점검과 유지관리가 필요하다.

지하 콘크리트 구조물

도시 기반시설의 보이지 않는 뼈대



이 연구가 다루는 세 결함

표면 상태 평가의 핵심 지표

클래스	형태적 정의	구조적 의미
crack (균열)	콘크리트 표면에 나타나는 선형·분기형·망상형의 불연속 영역	수분 및 유해 물질의 침투 경로가 될 수 있으며, 내구성 저하와 연관될 수 있다
efflorescence (백태)	수분 이동에 의해 표면에 형성되는 백색 또는 담색의 침착물	누수 또는 지속적인 수분 이동의 지표가 될 수 있다
spall_detach (박리·박락)	콘크리트 표면층의 분리, 들뜸 또는 재료의 부분 탈락 영역	피복 콘크리트의 분리·탈락으로 이어질 수 있으며, 철근 부식이나 재료 열화와 연관될 수 있다

이러한 표면 결함은 구조물의 열화 상태를 파악하는 중요한 단서가 되며, 진행 정도에 따라 내구성 저하, 단면 손실, 낙하 위험 등으로 이어질 수 있어 유지관리에서 주요 점검 대상으로 다뤄진다.

이 연구가 다루는 세 결함

표면 상태 평가의 핵심 지표

crack (균열)	콘크리트 표면에 나타나는 선형·분기형·망상형의 불연속 영역	
efflorescence (백태)	수분 이동에 의해 표면에 형성되는 백색 또는 담색의 침착물	
spall_detach (박리·박락)	콘크리트 표면층의 분리, 들뜸 또는 재료의 부분 탈락 영역	

육안 점검의 한계

왜 자동화가 필요한가

육안 점검의 장점

- 구조적 맥락과 주변 환경 조건을 함께 고려할 수 있다
- 현장에서 즉시 판단이 가능하다
- 점검자의 경험과 현장 지식이 판단에 반영될 수 있다
- 현장 점검에서 널리 활용되는 기본적인 평가 방식이다

한계

- 점검자의 경험·전문성·피로도에 영향을 받는다.
- 동일한 결함도 점검자에 따라 판단 결과가 달라질 수 있다.
- 장대 터널·공동구 점검에는 상당한 시간과 인력이 필요하다.
- 복잡한 배경과 낮은 가시성으로 결함과 비결함 요소의 구분이 어려울 수 있다.

지하 환경의 특수성

- 낮은 조도, 습기, 오염, 그림자 등 다양한 촬영 방해 요소가 존재한다.
- 케이블, 배관, 시공 이음부, 조명 설비 등 결함과 유사하게 보일 수 있는 요소가 함께 촬영된다.
- 이러한 복잡한 배경 조건은 자동 결함 탐지의 오탐·미탐 가능성을 높이는 주요 요인이다.

육안 점검의 한계

왜 자동화가 필요한가







영상 기반 점검의 장점

기록과 비교가 가능한 점검 방식

이점	내용	효과
반복 검토	촬영·기록된 영상을 여러 번 다시 확인할 수 있다	판단의 재현성과 객관성 확보
변화 추적	이전 점검 영상과 비교하여 결함의 진행 여부와 변화를 추적할 수 있다	결함 진행 속도와 상태 변화 파악 가능
접근 곤란 구역	무인기·이동식 카메라·터널 점검 차량·로봇 플랫폼 활용	사람이 가기 어려운 곳까지
대량 데이터 관리	대규모 점검 데이터를 체계적으로 관리	이력 축적과 통계 분석
특징 설계 불필요	딥러닝이 데이터에서 시각 패턴을 직접 학습	수작업 특징 설계 부담 제거

다만 촬영 조건이 다르면 결함의 외형도 달라진다. 영상 기반 점검은 촬영 조건을 통제하는 문제를 새로 만든다.

분류에서 검출로

무엇이 부족했는가

접근	연구	내용
이미지 분류	Özgenel & Sorguç — 사전학습 CNN으로 건물 균열 탐지	전이학습으로 소량 데이터에서도 균열/비균열 구분 가능
이미지 분류	Feng 등 — 심층 CNN과 전이학습으로 구조 손상 탐지	사전학습 모델이 손상 인식 성능을 개선
한계	결함 유무만 판정한다	어디에 있는지, 얼마나 퍼졌는지 알 수 없다
객체 검출	SSD · YOLOv3 · YOLOX · YOLOv7	실시간 검출로 결함 위치를 바운딩 박스로 제공
한계	박스는 손상 영역의 기하를 표현하지 못한다	균열은 가늘고 길어 박스 대부분이 배경이 된다

백태는 넓게 퍼지며 경계가 흐리고, 박리는 불규칙한 경계를 가진다. 사각형으로는 어느 쪽도 제대로 담기지 않는다.

세그멘테이션 연구의 흐름

픽셀 단위로 내려가다

Choi & Cha	SDDNet — 실시간 균열 세그멘테이션 가능성 검토
Ma & Ren	U-Net 기반 모델로 터널 균열 영역 분할
Ni 등	합성곱 특징 융합으로 픽셀 단위 균열 경계 추출 — 가는 균열의 미세 구조 보존이 중요
Nguyen & Thai	불균형 균열 데이터에서 손실함수 선택이 성능에 미치는 영향 분석
Tian 등	recall loss 기반 학습 전략으로 미검출 감소
Dorafshan 등	SDNET2018 — 비접촉 콘크리트 균열 탐지 데이터셋
Kulkarni 등	CrackSeg9k — 여러 균열 데이터셋 통합, 교차 데이터셋 비교의 필요성 제기

이 흐름의 공통점: 대부분 균열 하나만을 단일 클래스로 다뤘다. 실제 지하 구조물에서는 여러 결함이 함께 나타난다.

이 연구가 겨냥한 빈틈

다중 결함 + 임계값 기반 평가

실제 점검에서는 여러 종류의 표면 결함이 개별적으로가 아니라 함께 나타난다.
따라서 결함 유형을 구분하면서 각 결함의 공간적 범위를 표현하는 다중 결함 분석이 필요하다.

기존 연구의 초점	균열 단일 클래스 — 백태·박리는 함께 다루지 않음
배경 복잡도	Alipour & Harris — 특정 재료·배경으로 학습한 모델은 조건이 바뀌면 성능이 저하
이 연구의 접근	crack · efflorescence · spall_detach 세 클래스를 하나의 모델로 동시 처리
평가의 확장	마스크 기반 성능과 이미지 단위 선별 성능을 함께 평가
핵심 장치	클래스별 신뢰도 임계값 — 결함마다 다른 신뢰도 분포를 반영

"클래스마다 임계값을 다르게 둔다"는 것이 이 논문의 실용적 기여다. 단순하지만 현장에서 효과가 큰 장치다.

PART 2 · 2주차

데이터와 모델

주석 기준에서 학습 설정까지

PART 2 · 방법

전체 연구 프레임워크

논문 Figure 1 — 여섯 단계

01
영상 선별
AI Hub
지하구조물 영상

▸

02
폴리곤 주석
결함 경계를
다각형으로

▸

03
포맷 변환
YOLO
segmentation

▸

04
분할·검증
학습/검증/테스트
무결성 점검

▸

05
미세조정
YOLOv8s-Seg
사전학습 가중치

▸

06
이중 평가
mask mAP +
ON/OFF F1

04단계 데이터 무결성 점검이 눈에 띈다

- 영상–라벨 대응 관계, 누락 파일, 빈 라벨 파일, 클래스 ID, 좌표 형식을 모두 확인했다
- 지루한 작업이지만 이 단계를 건너뛰면 학습 중반에 원인 불명의 오류로 되돌아온다
- 학생 과제에서도 이 점검 스크립트를 먼저 만들어두면 시간을 크게 아낄 수 있다

데이터 출처와 클래스 재정의

AI Hub 공개 데이터를 다시 정의하다

원본 데이터

- AI Hub의 지하 콘크리트 구조물 공개 영상 데이터
- 공동구 등 지하 구조물 내부 콘크리트 표면 촬영
- 벽체·천장·바닥·시공 이음부가 함께 담김
- 케이블·배관·조명 설비·표면 오염도 포함

재정의가 필요했던 이유

- 원본 라벨이 채택한 결함 분류 체계와 완전히 일치하지 않았다
- crack · efflorescence · spall_detach 세 클래스로 재정의
- 각 결함 영역을 폴리곤 인스턴스 마스크로 수동 주석
- 연구 목적에 맞는 영상만 선별해 학습·검증·테스트로 배정

공개 데이터를 그대로 쓰지 않았다는 점

- 공개 데이터셋의 라벨 체계가 자기 연구 목적과 다른 경우는 흔하다
- 이때 라벨을 재정의하고 다시 주석하는 작업이 연구의 상당 부분을 차지한다
- 이 논문은 4,116장 전체를 폴리곤으로 다시 주석했다 — 결과 수치보다 이 노동이 연구의 실체에 가깝다

클래스 정의와 제외 대상

무엇을 결함으로 볼 것인가

클래스	포함 기준	제외 대상
crack	선형·분기형·망상형의 표면 불연속	시공 이음부, 케이블, 표면 긁힘, 그림자 등 균열처럼 보이는 비결함 선형 요소
efflorescence	수분 이동으로 형성된 백색·담색 침착물	정반사, 밝은 보수 재료, 먼지, 일반적 표면 변색
spall_detach	표면층 분리 또는 재료의 부분 탈락	(별도 제외 목록 없음 — 경계 판단이 핵심)

제외 대상을 명시하는 것이 주석 기준서의 핵심이다. 무엇이 결함인지보다 무엇이 결함이 아닌지를 정하는 일이 더 어렵다.

박리와 박락을 하나로 묶은 이유

분류 체계 설계의 판단

둘은 원래 다른 것이다

- 박리(delamination): 표면층이 들뜨며 분리되는 초기 단계
- 박락(spalling): 재료가 실제로 떨어져 나간 상태
- 발생 원인과 열화 진행 단계가 다르다
- 유지관리 조치도 달라질 수 있다

그럼에도 통합한 근거

- 영상에서 두 상태가 연속적인 열화 과정으로 나타나는 경우가 많다
- 명확한 경계로 구분하기 어렵다
- 억지로 나누면 주석 일관성이 무너진다
- 따라서 spall_detach 단일 클래스로 통합

통합의 대가 — 논문이 스스로 지적한 부분

- spall_detach는 클래스 내부의 시각적 변동성이 매우 크다
- 이 변동성 때문에 모델이 일관된 표현을 학습하기 어려울 수 있다
- 충분히 큰 데이터셋이 확보되면 박리와 박락의 분리 기준을 재검토해야 한다고 밝혔다

데이터셋 규모

학습 4,036 · 검증 40 · 테스트 40

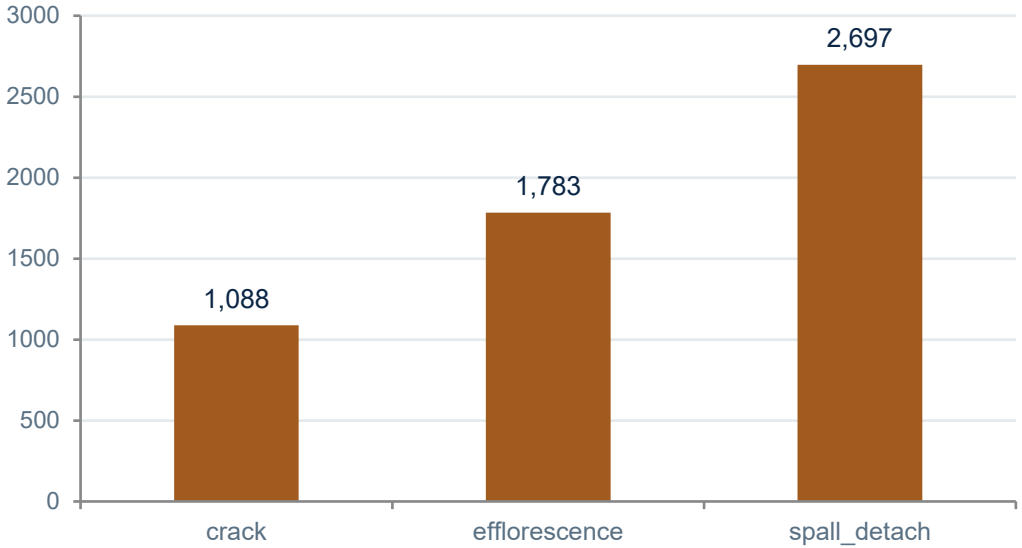
구분	영상 수	라벨 인스턴스	용도
학습 (train)	4,036장	5,568개	원본 + 증강 영상 포함
검증 (validation)	40장	53개	모델 선택 + 임계값 결정용 · 증강 없음
테스트 (test)	40장	47개	최종 평가 전용 · 증강 없음

검증·테스트가 40장뿐이라는 것

- 이미지 단위 ON/OFF 평가에서 1장이 곧 2.5%p다 — 그보다 작은 차이는 셀 수 없다
- 논문도 첫 번째 한계로 이 점을 명시했다: 지하 구조물의 넓은 조건 범위를 대표하기에 부족하다
- 다만 40장 전부를 수동 검토해 클래스와 경계의 적절성을 확인했다고 밝혔다

클래스별 영상 분포

한 영상에 여러 결함이 함께 있다



검증 / 테스트 분포

- 검증 — crack 10 · 백태 27 · 박리 16
- 테스트 — crack 14 · 백태 18 · 박리 15
- 합이 40을 넘는다 = 한 영상에 여러 클래스 공존
- spall_detach가 학습셋에서 가장 많다

클래스별 영상 수의 합(1,088+1,783+2,697)이 학습셋 4,036장을 넘는다. 다중 라벨 구조라는 뜻이다.

데이터 분할 원칙

이 논문이 특히 잘한 부분

원칙	내용	확보한 것
증강 영상 배제	검증셋과 테스트셋에는 증강 영상을 포함하지 않았다	평가 기준선을 원본으로 유지
원본 단위 분할	같은 원본에서 파생된 영상이 여러 부분집합에 흩어지지 않도록 구성	데이터 누수 차단
중복 영상 검토	중복되거나 시각적으로 유사한 영상을 검토해 반복 사용 방지	사실상 같은 샘플의 이중 계산 방지
테스트셋 고정	모델 선택이나 임계값 조정에 사용하지 않음	독립적 최종 평가 보장
주석 재검토	검증·테스트셋의 클래스와 경계를 확정 전에 재검토	라벨 신뢰도 확보

Step 1의 오버랩 윈도우, Step 2의 trial-wise 분할, Step 4의 증강 누수와 같은 계열의 문제다. 여기서는 제대로 지켜졌다.

폴리곤 인스턴스 주석

사각형이 아니라 다각형으로

crack	육안으로 식별 가능한 균열 경로를 따라 라벨링
efflorescence	표면에 육안으로 확인되는 침착물이 있는 영역을 구획
spall_detach	표면 분리 또는 콘크리트 재료 손실이 보이는 영역 기준
품질 관리	클래스 배정과 마스크 경계가 일관된 데이터만 유지
검증·테스트	평가와 임계값 결정에 직접 쓰이므로 확정 전 별도 검토

Step 4의 심비대 연구는 도구 제약으로 사각형 박스를 썼고 이를 한계로 밝혔다. 이 연구는 폴리곤으로 결함의 실제 기하를 담았다 — 대신 주석 비용이 훨씬 크다.

입력 처리 설정

letterbox 960과 증강 선택

항목	설정	근거
크기 조정	종횡비를 유지하며 리사이즈, 남는 영역은 letterbox 패딩	왜곡 없이 크기 통일
입력 크기	960	작은 결함과 가는 균열의 세부를 최대한 보존
Mosaic 증강	비활성화	지하 콘크리트 표면의 공간적 맥락을 과도하게 왜곡할 수 있어서
MixUp 증강	비활성화	같은 이유 — 두 영상을 섞으면 결함 경계가 물리적으로 무의미해진다

증강을 끄는 것도 선택이고 근거가 필요하다. 일반 물체 검출에서 표준인 Mosaic가 결함 탐지에서는 해가 될 수 있다.

YOLOv8s-Seg 구조

검출과 분할을 하나의 네트워크에서

Backbone

입력 영상에서 다중 스케일 특징 추출

Neck

서로 다른 공간 해상도의 특징을 융합

Detection Head

결함의 위치와 클래스를 예측

Segmentation Branch

검출된 각 결함에 대해 인스턴스 마스크 생성

$$P = \{ (b_i , c_i , s_i , m_i) \}\ i=1..N$$

박스 · 클래스 · 신뢰도 · 마스크

모델 선택의 근거

- 가늘고 불규칙한 균열 패턴을 학습하는 데 필요한 표현력과, 현장 배치 가능성을 위한 계산 효율을 함께 고려했다
- s(small) 크기를 고른 것은 이 절충의 결과다 — 더 큰 모델은 성능이 오르지만 현장 배치가 어려워진다
- yolov8s-seg.pt 사전학습 가중치로 초기화한 뒤 3클래스 데이터셋에서 미세조정했다

학습 설정

논문 Table 1

모델	YOLOv8s-Seg
초기 가중치	사전학습 가중치 (yolov8s-seg.pt)
입력 크기	960
클래스	crack · efflorescence · spall_detach
학습/검증/테스트	4,036 / 40 / 40
에폭	60
배치 크기	4
옵티마이저	AdamW
초기 학습률	0.00015
모델 선택	검증셋에서 최고 성능을 보인 에폭

입력 960에 배치 4는 GPU 메모리 제약을 그대로 보여준다. 고해상도를 택하면 배치를 줄여야 하는 절충이 발생한다.

학습 중 관찰한 손실

네 가지 손실을 함께 본다

손실	의미	확인하는 것
Box loss	바운딩 박스 좌표 회귀 오차	결함 위치를 얼마나 잘 잡는가
Segmentation loss	마스크 예측 오차	결함 경계를 얼마나 잘 그리는가
Classification loss	클래스 분류 오차	결함 종류를 얼마나 잘 맞히는가
Distribution focal loss	박스 좌표 분포 학습 오차	경계 위치의 불확실성을 다룬다

학습 손실은 줄었지만 검증은 흔들렸다

- 학습 손실은 비교적 꾸준히 감소했으나, 검증 손실과 검증 성능은 여러 에폭에서 요동쳤다
- 따라서 학습 손실이 감소한다는 이유만으로 최종 모델을 고르지 않았다
- 검증 성능이 가장 높은 에폭의 모델을 최종 평가에 사용했다 — 올바른 모델 선택 절차

PART 3 · 3주차

평가와 임계값

두 개의 자로 재는 이유

마스크 기반 평가 지표

경계를 얼마나 정확히 그렸는가

지표	정의	재는 것
Precision	예측한 것 중 실제 결함의 비율	오탐의 정도
Recall	실제 결함 중 찾아낸 비율	미탐의 정도
mask mAP50	IoU 임계 0.50에서 계산한 클래스별 AP의 평균	대략적 위치와 범위를 맞혔는가
mask mAP50-95	IoU 0.50~0.95를 0.05 간격으로 평균	엄격한 경계 정확도까지 요구

박스가 아니라 마스크 기준을 쓴 이유

- 이 연구의 목표는 실제 손상 영역의 위치 파악과 분할이다
- 따라서 바운딩 박스 기반 지표가 아니라 마스크 기반 지표에 분석을 집중했다
- 평가 지표를 고를 때는 연구 목적이 무엇인지부터 되물어야 한다

이미지 단위 ON/OFF 평가

이 논문의 핵심 아이디어

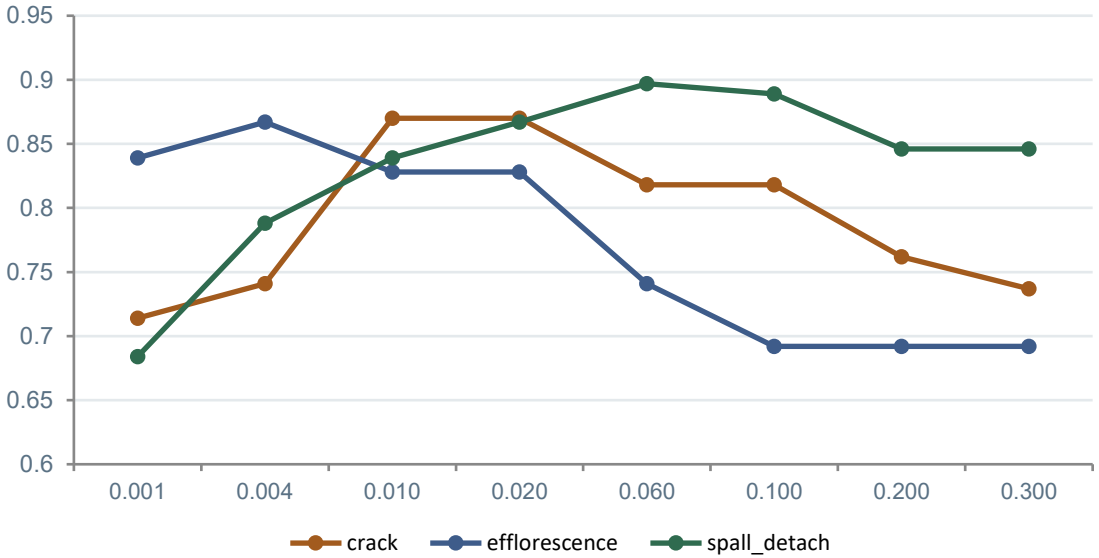
**실제 점검에서는 분할 영역의 경계 정확도뿐 아니라,
결함이 있는 영상을 우선순위로 골라내는 능력도 중요하다.**

정답 ON	해당 클래스의 정답 인스턴스가 영상에 하나라도 있으면 ON
예측 ON	해당 클래스의 예측 인스턴스 중 신뢰도가 임계값 이상인 것이 하나라도 있으면 ON
산출 지표	클래스별 TP · FP · FN · TN → precision · recall · F1
종합 지표	세 클래스 F1의 평균 = macro F1-score

경계가 조금 어긋나도 결함이 있는 영상을 골라내기만 하면 성공으로 친다. 실무 워크플로에 맞춘 평가 방식이다.

검증셋 임계값 탐색

논문 Table 3 — 클래스마다 최적점이 다르다



곡선 모양이 다르다

- crack — 0.010~0.020에서 정점 후 하강
- efflorescence — 0.004에서 정점, 이후 계속 하강
- spall_detach — 0.060에서 정점, 높은 임계에서도 견딤

세 곡선의 정점이 서로 다르다는 사실이 클래스별 임계값을 정당화한다. 하나의 공통 임계값으로는 세 클래스를 모두 만족시킬 수 없다.

선택된 임계값과 검증 성능

논문 Table 2

지표	crack	efflorescence	spall_detach
선택 임계값	0.010	0.004	0.060
Precision	0.769	1.000	0.812
Recall	1.000	0.765	1.000
F1-score	0.870	0.867	0.897
False Positive	3	0	3
False Negative	0	4	0

crack은 0.010과 0.020에서 F1이 같아 가는 균열 미검출을 줄이려 낮은 쪽을, 백태는 오탐 0인 0.004를, 박리는 미탐 0인 0.060을 골랐다.

임계값이 만드는 교환 관계

낮추면 얻는 것과 잃는 것

임계값을 낮추면

- 더 많은 예측을 남긴다
- Recall이 올라간다 — 놓치는 결함이 줄어든다
- 동시에 오탐(False Positive) 위험이 커진다
- 가는 균열처럼 신뢰도가 낮게 나오는 결함에 유리

임계값을 높이면

- 확신이 높은 예측만 남긴다
- 오탐이 줄어든다
- 낮은 신뢰도로 예측된 진짜 결함을 버리게 된다
- False Negative가 늘어난다

클래스마다 최적점이 다른 이유

- crack — 가늘고 영상에서 차지하는 비율이 작아 진짜 균열도 낮은 신뢰도를 받는다. 높은 임계값은 미탐을 키운다
- efflorescence — 밝은 침착물이 뚜렷하면 잘 잡히지만, 옅거나 넓게 퍼지거나 경계가 흐리면 신뢰도가 떨어진다
- spall_detach — 심한 재료 손실은 높은 신뢰도를 얻지만, 초기 박리나 배경과 질감이 비슷한 결함은 불안정하다

세그멘테이션 성능

논문 Table 4 — 테스트셋 결과

mask mAP50

0.443

mask mAP50-95

0.222

이 숫자를 어떻게 볼 것인가

- 일반 물체 검출 기준으로 보면 낮은 편이다 — COCO 벤치마크에서 mAP50 0.443은 평범한 수준
- 그러나 결함 세그멘테이션에서는 사정이 다르다. 균열은 폭이 몇 픽셀에 불과해 1~2픽셀만 어긋나도 IoU가 급락한다
- mAP50에서 mAP50-95로 갈 때 절반으로 떨어진다는 것은, 대략적 위치는 맞히지만 엄격한 경계 정확도는 못 맞춘다는 뜻이다
- 이 한계를 인정하고 나온 대안이 바로 이미지 단위 ON/OFF 평가다

왜 엄격한 경계 정확도가 어려운가

결함 종류별 이유

클래스	시각적 특성	경계 정확도에 미치는 영향
crack	폭이 좁다	예측 마스크가 몇 픽셀만 어긋나도 IoU가 크게 떨어진다
efflorescence	경계가 흐리고 확산적이다	정답 마스크와 예측 마스크의 일치도가 본질적으로 낮아진다
spall_detach	그림자·표면 요철·주변 질감과 결합	정확한 경계 추정 자체가 어렵다

이것은 모델의 잘못이라기보다 대상의 성질이다. 사람이 주석해도 경계가 사람마다 달라지는 대상에서 높은 IoU를 요구하는 것 자체가 무리다.

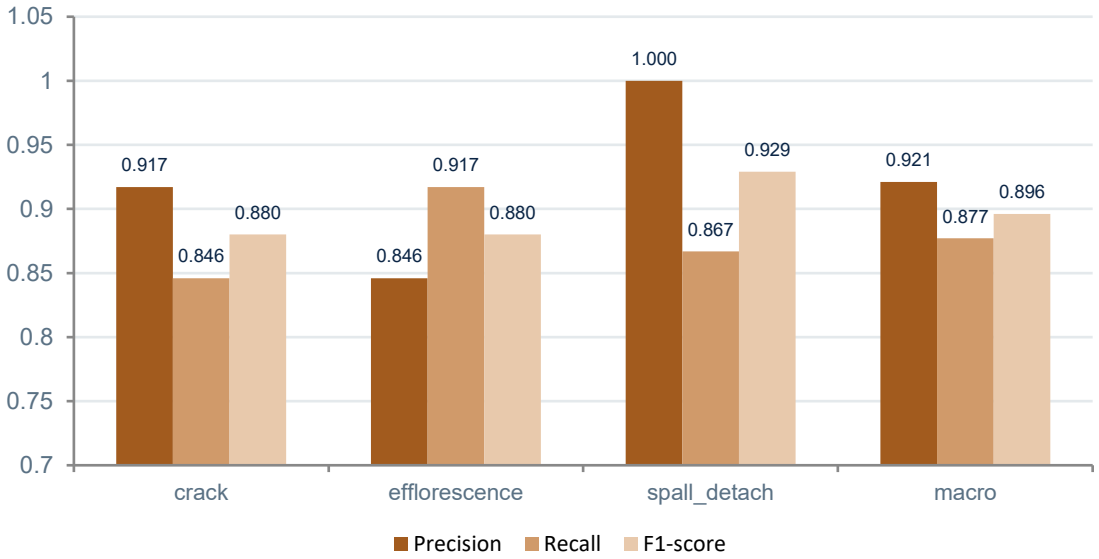
테스트셋 ON/OFF 결과

논문 Table 5 — 임계값을 고정 적용

지표	crack	efflorescence	spall_detach	macro
임계값	0.010	0.004	0.060	—
True Positive	11	11	13	—
True Negative	26	26	25	—
False Positive	1	2	0	—
False Negative	2	1	2	—
Precision	0.917	0.846	1.000	0.921
Recall	0.846	0.917	0.867	0.877
F1-score	0.880	0.880	0.929	0.896

ON/OFF 성능 시각화

세 클래스 모두 F1 0.88 이상



주목할 점

- spall_detach 정밀도 1.000 — 오탐 0건
- crack은 정밀도 높고 재현율 낮다
- efflorescence는 그 반대
- 검증 macro 0.878 → 테스트 0.896

검증에서 정한 임계값을 테스트에 그대로 적용했는데 오히려 성능이 조금 올랐다. 임계값이 과적합되지 않았다는 신호다.

두 평가 지표의 관계

왜 둘 다 필요한가

지표	재는 방식	평가하는 능력	결과
mask mAP	예측 마스크와 정답 마스크의 겹침 정도	결함 위치 파악과 경계 정확도	0.443 / 0.222
ON/OFF F1	영상에 해당 클래스 결함이 있는지 여부	결함 포함 영상의 선별 능력	0.896

실무 워크플로에서의 의미

- 경계가 완벽하지 않아도 결함이 있는 영상을 골라내는 성능은 안정적으로 유지되었다
- 대규모 점검 데이터에서 결함 가능성이 있는 영상을 우선순위로 올리는 것이 1차 목적이라면 이 성능으로 충분하다
- 따라서 지하 구조물 결함 분석은 마스크 기반 성능과 이미지 단위 선별 성능을 함께 평가해야 한다는 것이 논문의 주장이다

정성적 예측 결과

어디서 잘 되고 어디서 안 되는가

잘 예측된 경우

- 배경과 명암 대비가 뚜렷한 큰 결함
- 넓게 분포한 백태로 주변 콘크리트와 명확히 구분되는 경우
- 시각적으로 뚜렷한 spall_detach 결함
- 이 경우 예측 마스크가 정답 영역과 잘 대응했다

어긋난 경우

- 가는 균열, 어두운 영역의 균열
- 경계가 확산적인 백태
- 주변 표면과 질감이 유사한 spall_detach 영역
- 부분적 누락 또는 영역 불일치가 관찰되었다

클래스별 예측 특성

- crack — 주된 경로는 대체로 검출되지만 가는 분기와 미세 균열이 종종 누락된다
- efflorescence — 침착 영역이 시각적으로 뚜렷하면 일관되게 예측되나 확산적 경계에서 정답과 차이가 발생한다
- spall_detach — 표면 손상이 뚜렷하면 잘 대응하나 주변과 질감이 비슷하면 일부 영역을 놓친다

클래스별 오류 특성

논문 Table 6

항목	crack	efflorescence	spall_detach
False Positive	1	2	0
False Negative	2	1	2
미탐 원인	좁은 폭, 낮은 대비, 어두운 배경, 불연속 균열	확산적 경계, 옅은 침착물, 작은 영역	배경과 유사한 질감, 초기 단계 박리, 모호성
오탐 원인	시공 이음부, 케이블, 그림자, 표면 긁힘	정반사, 밝은 보수 재료, 표면 오염	표면 요철, 그림자, 보수 흔적

오류가 알려주는 것

데이터를 어떻게 보강해야 하는가

오류 유형	원인	개선 방향
crack 미탐	매우 좁거나 명암 대비가 낮은 균열. 입력 리사이즈 과정에서 특징이 소실될 수 있다	고해상도 타일 추론 검토
crack 오탐	균열을 닮은 선형 요소 — 이음부·케이블·그림자·긁힘	하드 네거티브 수집
백태 미탐	옅은 침착물, 확산적 경계	저강도 백태 사례 보강
백태 오탐	정반사, 밝은 보수 재료, 표면 오염	색·밝기에 강하게 의존한다는 신호
박리 미탐	초기 단계 박리, 배경과 질감 대비 부족	초기 사례 표적 수집
경계 모호	예측이 타당해 보이나 정답 경계와 범위가 다름	주석 지침의 반복적 정교화 필요

평가 결과가 주석 기준에 따라 달라질 수 있으므로, 반복적인 오류 분석으로 라벨링 지침을 다듬어야 한다는 것이 논문의 결론이다.

PART 4 · 마무리

한계와 실무 적용

이 결과로 무엇을 할 수 있는가

논문이 밝힌 한계

네 가지

01	**검증·테스트 각 40장**	지하 구조물의 넓은 조건 범위를 대표하기 어렵다. 다른 터널·공동구·지하차도, 다른 촬영 장비와 조명 조건에서의 외부 검증이 필요
02	**물리 단위 정량화 불가**	균열 폭, 실제 결함 면적, 깊이, 박리 내부 상태를 물리 단위로 산출할 수 없다. 타격음·열화상 등 비파괴 검사와의 통합이 필요
03	**입력 960 리사이즈**	매우 좁은 균열의 시각적 특징이 전처리에서 약화될 수 있다. 타일 기반 고해상도 추론이 대안이나 연산 시간과 중복 검출 문제가 따른다
04	**단일 모델**	U-Net · DeepLabv3+ · Mask R-CNN · SegFormer 등과의 직접 비교가 없다. 반복 학습의 평균±표준편차, 연산 복잡도, 추론 속도 보고도 필요

한계를 네 개나 명시하고 각각에 대안까지 제시했다. 이것이 심사에서 신뢰를 얻는 서술 방식이다.

실무에서의 위치

판정 도구가 아니라 의사결정 지원 도구

이 시스템이 할 수 있는 것

- 대규모 지하 구조물 데이터에서 결함 가능성이 있는 영상을 우선순위로 제시
- 점검자에게 결함 후보 영역을 제시
- 이전 점검 결과와 비교해 변화를 추적
- 접근이 어려운 구역의 기록을 체계적으로 관리

최종 판단에 필요한 것

- 균열 폭 등 물리적 계측
- 누수 여부와 철근 부식 상태
- 결함의 진행 정도
- 해당 부재의 구조적 중요도

이 구분이 왜 중요한가

- 논문은 "final maintenance decisions should incorporate image-based predictions and field information"이라고 명시했다
- AI가 판정하는 것이 아니라 점검자의 판단을 돕는 위치에 시스템을 두는 설계다
- Step 4의 의료 AI에서도 같은 구조를 봤다 — 최종 책임은 사람에게 있고 AI는 우선순위를 제시한다

향후 연구 방향

논문이 남긴 과제

방향	내용	기대 효과
외부 검증	더 넓은 범위의 시설물 유형과 촬영 조건에서 평가	일반화 성능 확인
주석 기준 정교화	spall_detach 클래스의 라벨링 기준 재정의	클래스 내 변동성 축소
하드 샘플 보강	가는 균열, 저강도 백태, 초기 박리 사례 추가	클래스별 탐지 성능 개선
타일 기반 추론	원본을 겹치는 타일로 나누어 고해상도 추론	미세 균열 검출력 향상
모델 비교	U-Net · DeepLabv3+ · Mask R-CNN · SegFormer	구조별 장단점 파악
비파괴 검사 통합	타격음 검사, 열화상 등과 결합	박리 내부 상태 판단

타일 기반 추론은 겹침 설정과 중복 제거 절차를 함께 설계해야 한다. Step 3 실습에서 직접 다뤄볼 만한 주제다.

STEP 3 · 실습

재현 실습 과제

주석부터 임계값까지

1단계	데이터 확보
2단계	주석 기준서
3단계	분할 설계
4단계	학습
5단계	임계값 탐색
6단계	최종 평가

5단계에서 테스트셋을 보고 임계값을 조정하고 싶은 유혹이 반드시 생긴다. 그 순간 실험이 무효가 된다는 점을 기억할 것.

STEP 3 · 실습

심화 도전 과제

기본 재현을 끝낸 학생을 위한 확장

타일 기반 추론	원본을 겹치는 타일로 나눠 추론하고 중복 제거 — 미세 균열 검출 개선	난이도 ★★★
모델 비교	U-Net 또는 Mask R-CNN을 같은 데이터로 학습해 비교	난이도 ★★★
하드 네거티브 수집	이음부·케이블·그림자 영상을 배경으로 추가해 오탐 감소 측정	난이도 ★★
공통 임계값 대조	단일 임계값 대비 클래스별 임계값의 이득을 정량화	난이도 ★★
반복 학습	시드 3~5개로 반복해 평균±표준편차 산출	난이도 ★★
균열 폭 정량화	스켈레톤화 + 거리 변환으로 픽셀 단위 폭 산출 후 스케일 환산	난이도 ★★★★

네 번째 항목이 이 논문의 핵심 주장을 직접 검증한다. 클래스별 임계값이 정말 이득인지 숫자로 보여주는 실험이다.

STEP 3 · 정리

실험 설계에서 배울 것

이 논문이 제대로 한 것들

설계 요소	내용	확보한 것
주석 기준 명시	클래스별 포함 기준과 제외 대상을 본문에 서술	라벨 재현성 확보
원본 단위 분할	같은 원본에서 나온 영상이 분산되지 않도록 구성	데이터 누수 차단
증강 범위 제한	검증·테스트셋에 증강 영상 미포함	평가 기준선 유지
임계값 절차 분리	검증셋에서 결정 → 테스트에 고정 적용	정보 누출 방지
모델 선택 기준	학습 손실이 아니라 검증 성능 기준	과적합 모델 선택 방지
평가 축 이원화	mask mAP + 이미지 단위 ON/OFF	목적에 맞는 평가

mAP 0.443이라는 숫자만 보면 아쉬운 연구로 보이지만, 절차의 엄밀함으로 결론을 지켜낸 사례다.

STEP 3 · 정리

비판적으로 읽는 연습

주장과 근거를 나누어 보기

논문의 주장	근거	검토
"실무 선별에 활용 가능"	테스트 macro F1 0.896	근거로 타당. 다만 테스트 40장 — 1장이 2.5%p
"클래스별 임계값이 필요"	세 클래스의 F1 곡선 정점이 다름	타당. 단 공통 임계값과의 직접 비교는 없다
"YOLOv8s-Seg가 적절"	표현력과 계산 효율의 절충으로 선택	다른 모델과 비교하지 않았으므로 가설 수준
"경계 정확도의 한계는 대상 탓"	균열 폭·백태 경계·박리 질감으로 설명	설득력 있으나 정량적 검증은 없다

이 표를 만드는 연습이 논문 읽기의 핵심이다. 저자를 공격하려는 것이 아니라 어디까지가 확인된 사실인지 선을 긋는 작업이다.

Step 3 체크리스트

제출 전 스스로 확인할 것

제출 전 확인 사항

- 주석 기준서에 클래스별 제외 대상을 명시했는가
- 원본 단위로 분할해 같은 원본의 파생 영상이 분산되지 않았는가
- 검증·테스트셋에 증강 영상이 섞이지 않았는가
- 임계값을 검증셋에서 결정하고 테스트에 고정 적용했는가
- mask mAP와 이미지 단위 ON/OFF F1을 모두 보고했는가
- 클래스별 FP·FN 사례를 실제 이미지로 제시하고 원인을 서술했는가
- 모델 선택 기준이 검증 성능이었음을 명시했는가
- 테스트셋 크기와 그로 인한 해상도 한계를 밝혔는가

가장 흔한 감점 사유: 테스트셋 결과를 보고 임계값을 되돌아가 조정하는 것. 코드 실행 순서로 증명할 수 있게 정리할 것.

정리와 다음 단계

Step 4로 넘어가기

Step 3에서 익힌 것

- 분류·검출·세그멘테이션의 선택 기준
- 폴리곤 주석과 기준서 작성
- 원본 단위 분할과 증강 범위 통제
- YOLOv8-Seg 학습과 모델 선택
- mask mAP와 이미지 단위 평가의 구분
- 클래스별 임계값 최적화 절차

Step 4로 이어지는 것

- 데이터 누수 방지 원칙
- 임계값 결정 절차
- FP·FN 원인 분석
- 한계를 명시하는 태도

Step 4 예고 — 의료영상 질병 탐지

같은 이미지 분류지만 요구 수준이 다르다. IRB · 개인정보 · 임상 지표가 기술만큼 중요해지는 영역으로.

DAEGU
CATHOLIC
UNIVERSITY

Thank you

DATA INTELLIGENCE LAB

Http://dil.cu.ac.kr/ 데이터 지능 연구실